


Preprocessing Data

Kualitas Kopi Arabika

Present by Eolia Shalbillah - 2318039



Daftar Pembahasan

- **Latar Belakang**
- **Gambaran Umum Dataset**
- **Permasalahan Dataset Raw**
- **Pre-processing yang Dilakukan**
- **Penjelasan Kode**
- **Hasil Akhir**
- **Kesimpulan**



Latar Belakang



Kualitas Data

Data mentah di dunia nyata sering kali mengandung missing values, format tidak konsisten, serta karakter asing yang dapat menurunkan performa analisis atau model machine learning.



Pentingnya Preprocessing

Proses pembersihan dan transformasi data (data cleaning & feature engineering) sangat krusial untuk memastikan keakuratan, konsistensi, dan kesiapan data sebelum diolah lebih jauh.



Tujuan Proyek

Mengubah dataset mentah Kopi Arabika (df_arabica.csv) menjadi dataset bersih (ready-to-use) tanpa menghilangkan informasi penting

Gambaran Umum Dataset

- Dataset berasal dari Kaggle: <https://www.kaggle.com/datasets/fatihb/coffee-quality-data-cqi>
- Nama File Dataset: df_arabica.csv
- Data Mentah memiliki 207 baris dan 41 kolom.
- Tipe yang Dimiliki Dataset: 13 Kolom float64, 6 Kolom int64: Fitur kuantitatif, dan 22 Kolom object.

	A	B	C	D	E	F	G	H	I	J	K	L	M
1		ID	Country of Origin	Farm Name	Lot Number	Mill	ICO Number	Company	Altitude	Region	Producer	Number of Bags	Bag Weight
2	0	0	Colombia	Finca El Paraíso	CQU2022015	Finca El Paraíso		Coffee Quality Union	1700-1930	Piendamó,Cauca	Diego Samuel Berni	1	35 kg
3	1	1	Taiwan	Royal Bean Geisha Estate	The 2022 Pacific Rim Coffee Competition	Royal Bean Geisha Estate		Taiwan Coffee Laboratory	1200	Chiayi	曾福森	1	80 kg
4	2	2	Laos	OKLAO coffee farms	The 2022 Pacific Rim Coffee Competition	oKao coffee processing plant		Taiwan Coffee Laboratory	1300	Laos Borofen Plateau	WU TAO CHI	19	25 kg
5	3	3	Costa Rica	La Cumbre	CQU2022017	La Montana Tarrazú Mill		Coffee Quality Union	1900	Los Santos,Tarrazú	Santa María de Dota	1	22 kg
6	4	4	Colombia	Finca Santuario	CQU2023002	Finca Santuario		Coffee Quality Union	1850-2100	Popayan,Cauca	Camilo Merizalde	2	24 kg
7	5	5	Guatemala	La Colina	The 2022 Pacific Rim Coffee Competition	Dinámica Café		Taiwan Coffee Laboratory	1668	Chimaltenango	Emilio Antonio Medina	5	30 kg
8	6	6	Taiwan	野牡丹咖啡莊園 Meia	The 2022 Pacific Rim Coffee Competition	野牡丹咖啡		Taiwan Coffee Laboratory	1250	Chiayi	黃保鏢	1	27 kg
9	7	7	Taiwan	七彩琉璃咖啡莊園 Ch	The 2022 Pacific Rim Coffee Competition	七彩琉璃咖啡莊園		Taiwan Coffee Laboratory	1200	Chiayi	莊家榮	1	90 kg
10	8	8	Taiwan	亮軒咖啡莊園 Liang X	The 2022 Pacific Rim Coffee Competition	亮軒咖啡莊園		Taiwan Coffee Laboratory	1250	Chiayi	鍾旭亮	1	30 kg
11	9	9	Tanzania, United Re	MASHIMA AMCOS	CN 4127230034/418	GOURMET COFFEE 033/DE/503/002 and		DORMAN (T) LIMITE	1400-1700	KILIMANJARO	DORMAN (T) LIMITE	320	60 kg
12	10	10	Ethiopia	TADE GG	010/0296/600	Moledo社 委託精選	010/0296/600	Manubeni corp.,	1800-2200	Guji	Tesfaye Bekele Deg	10	30 kg
13	11	11	Guatemala	Karen Acajabon Coff	The 2022 Pacific Rim Coffee Competition	Cafetoland		Taiwan Coffee Laboratory	2000	Acatenango	Karen Acajabon	5	15 kg
14	12	12	Taiwan	古峰咖啡莊園 Goodfu	The 2022 Pacific Rim Coffee Competition	古峰咖啡莊園		Taiwan Coffee Laboratory	1250	Yunlin	賴添合	1	60 kg
15	13	13	Ethiopia	Gelana Geisha	Grade 1, Guji, Natur	Dry Mill or Hulling F	010/0475/0207	Kerchanshe Trading	1900-2000	Guji	Kerchanshe	40	60 kg
16	14	14	Colombia	La Gaitania	The 2022 Pacific Rim Coffee Competition	La Gaitania		Taiwan Coffee Laboratory	1850	tolima	Josue Enciso Suarez	70	35 kg
17	15	15	Taiwan	青葉咖啡莊園	The 2022 Pacific Rim Coffee Competition	青葉咖啡莊園		Taiwan Coffee Laboratory	1100	Chiayi	葉世遠	1	60 kg
18	16	16	Ethiopia	Halo Bariti Cooperativ	CQU2023006	Halo Bariti Cooperative		Coffee Quality Union	1900-2100	Gedeb,Yingacheffe,£	Halo Bariti Cooperativ	8	5 kg
19	17	17	Taiwan	東璧咖啡莊園	202203	yes	non	Dongbi coffee	1300	Shibi, Gukeng Town	陳景立	5	2 kg
20	18	18	Taiwan	櫻桃果古坑咖啡莊園	202112	yes	non	宸峰國際有限公司	1200	Gukeng Township, Y	王澄惠	8	1 kg
21	19	19	Tanzania, United Re	BURKA	CN 4127230032/P-9	GOURMET COFFEE 033/DE/163/001		DORMAN (T) LIMITE	1570-1600	Arusha	DORMAN (T) LIMITE	200	30 kg
22	20	20	Guatemala	Finca Vista Hemosa	The 2022 Pacific Rim Coffee Competition	El Vergel		Taiwan Coffee Laboratory	1900	Guatemala, Fraijanes	Fredy Orantes	8	30 kg
23	21	21	Taiwan	仲大叔咖啡莊園 Uncle	2022/03	仲大叔咖啡莊園 Uncle	Chung.s Coffee Farm	Taiwan Coffee Laboratory	850	卓溪鄉Zhuoxi Towns	游舜清 YU TING YU	1	20 kg
24	22	22	Thailand	Hom Doi	1	Machines to peel outer skin of the cherry c	Lyrose		1500-1700	Chiang Mai	Lisu farmers	2	1 kg
25	23	23	Colombia	El Diamante	CQU2023005	El Diamante		Coffee Quality Union	1350	Quindío	Farm Bedoya Arango	6	5 kg
26	24	24	Taiwan	永興咖啡莊園	The 2022 Pacific Rim Coffee Competition	永興咖啡莊園		Taiwan Coffee Laboratory	1250	Yunlin	蘇甘永	4	50 kg
27	25	25	Brazil	Fazenda Recreio	Arara 1	Dry mill		WIT wealth, investme	1250	Região Vulcânica	Diogo T. Dias de Ma	25	60 kg
28	26	26	Taiwan	鄉榮園ZouZhouYuan	The 2022 Pacific Rim Coffee Competition	鄉榮園ZouZhouYuan		Taiwan Coffee Laboratory	1300	Chiayi	方政倫	1	100 kg
29	27	27	Taiwan	崙岳咖啡莊園	The 2022 Pacific Rim Coffee Competition	崙岳咖啡莊園		Taiwan Coffee Laboratory	1200	Yunlin	郭志豪	1	90 kg
30	28	28	Taiwan	他扶芽有機農場	The 2022 Pacific Rim Coffee Competition	他扶芽有機農場		Taiwan Coffee Laboratory	1060	Chiayi	陳清龍	1	85 kg
31	29	29	United States (Hawai	Hokukano Ranch	The 2022 Pacific Rim Coffee Competition	Kona Coffee & Tea		Taiwan Coffee Laboratory	600	Kona	Kona Hills LLC	80	15 kg
32	30	30	Taiwan	鄉庭有機農場Siang-T	2022/3/1(老農)	鄉庭有機農場Siang-Ting Organic Farm		Taiwan Coffee Laboratory	150-250	壽豐鄉Shoufeng Tow	張進義Zhang Jin-Yi	3	48 kg

Permasalahan Dataset Raw

- **Redundansi Kolom:** Adanya kolom indeks ganda (Unnamed: 0)
- **Missing Value Tingkat Tinggi:** Kolom ICO Number kehilangan 132 data (>50% data kosong).
- **Format Teks:** Kolom Bag Weight berupa gabungan angka dan teks ("35 kg")
- **Format Teks:** Kolom Altitude memuat nilai rentang string ("1700-1930").
- **Format Tanggal Tidak Standar:** Terdapat imbuhan (st, nd, rd, th) pada tanggal ("April 21st, 2023").
- **Karakter Non-Latin:** Beberapa kolom teks terdapat aksara non-Latin yang berpotensi memicu encoding error.

Pre-processing yang Dilakukan



Pembersihan Redundansi & Pengisian Missing Value:

- Menghapus kolom Unnamed: 0 dan ICO Number.
- Mengisi nilai kosong kategorikal dengan label 'Unknown'.



Ekstraksi & Standarisasi Fitur Numerik:

- Mengisolasi berat angka dari teks unit pada Bag Weight.
- Menghitung rerata (mean) nilai rentang pada Altitude.



Standarisasi Tipe Datetime:

- Menghapus imbuhan ordinal dan mengonversi format tanggal ke YYYY-MM-DD.



Pembersihan Teks & Deduplikasi:

- Filter karakter non-Latin serta trimming spasi berlebih (str.strip()).
- Verifikasi dan eliminasi data terduplikat.

Penjelasan Kode

A. Persiapan & Import Library

✓ A. Persiapan & Import Library

✓ 1. Connect Google Drive

```
[1] ✓ 23 d from google.colab import drive  
drive.mount('/content/drive')
```

✓ Mounted at /content/drive

✓ 2. Import Library

```
[2] ✓ 1 d import matplotlib.pyplot as plt  
import numpy as np  
import pandas as pd  
import re  
import seaborn as sns
```

- `from google.colab import drive`: Mengimpor fungsi untuk menyambungkan Google Drive ke Colab.
- `drive.mount('/content/drive')`: Menghubungkan direktori Google Drive agar file di dalamnya bisa diakses.
- `import matplotlib.pyplot as plt`: Mengimpor pustaka Matplotlib untuk membuat visualisasi data dan grafik.
- `import numpy as np`: Mengimpor pustaka NumPy untuk operasi matriks dan perhitungan numerik.
- `import pandas as pd`: Mengimpor pustaka Pandas untuk mengolah dan membersihkan data dalam tabel (DataFrame).
- `import re`: Mengimpor modul Regular Expression untuk pemrosesan dan pembersihan teks/pola string.
- `import seaborn as sns`: Mengimpor pustaka Seaborn untuk membuat tampilan grafik statistik yang lebih rapi.

Penjelasan Kode

A. Persiapan & Import Library

```
3. Memindai Lokasi Dataset di Google Drive

[3]
✓ 0 d file_path = '/content/drive/MyDrive/2026GoogleColab_DataMining/Tugas1/Dataset/df_arabica.csv'

4. Membaca Dataset

[4]
✓ 2 d df = pd.read_csv(file_path)

print("Dataset berhasil dibaca!")
print(f"Jumlah baris: {df.shape[0]} | Jumlah kolom: {df.shape[1]}")

Dataset berhasil dibaca!
Jumlah baris: 207 | Jumlah kolom: 41

Dataset yang digunakan memiliki 207 baris dan 41 kolom
```

- `file_path = '/content/drive/MyDrive/...'`: Menyimpan lokasi alamat file dataset `df_arabica.csv` ke dalam variabel.
- `df = pd.read_csv(file_path)`: Membaca file CSV dari jalur lokasi ke dalam variabel DataFrame `df`.
- `print("Dataset berhasil dibaca!")`: Menampilkan pesan konfirmasi bahwa proses pembacaan file telah selesai.
- `print(f"Jumlah baris: {df.shape[0]} | Jumlah kolom: {df.shape[1]}")`: Menampilkan dimensi dataset berupa jumlah total baris dan kolom secara dinamis.

Penjelasan Kode

B. Eksplorasi Data Awal

B. Eksplorasi Data Awal

1. Menampilkan 10 Dataset Teratas

```
[5] print("--- 10 Baris Pertama Dataset ---")
display(df.head(10))
```

10 Baris Pertama Dataset ---

Unnamed: 0	ID	Country of Origin	Farm Name	Lot Number	Mill	ICO Number	Company	Altitude	Region	Total Cup Points	Moisture Percentage	Category One Defects	Quakers	
0	0	0	Colombia	Finca El Paraiso	CQU2022015	Finca El Paraiso	NaN	Coffee Quality Union	1700-1930	Piendam, Cauca	89.33	11.8	0	0
1	1	1	Taiwan	Royal Bean Geisha Estate	The 2022 Pacific Rim Coffee Summit, T037	Royal Bean Geisha Estate	NaN	Taiwan Coffee Laboratory	1200	Chiayi	87.58	10.5	0	0
2	2	2	Laos	OKLAO coffee farms	The 2022 Pacific Rim Coffee Summit, LA01	oklao coffee processing plant	NaN	Taiwan Coffee Laboratory	1300	Laos Borofen Plateau	87.42	10.4	0	0
3	3	3	Costa Rica	La Cumbre	CQU2022017	La Montana Tarrazu Mill	NaN	Coffee Quality Union	1900	Santos, Tarrazu	87.17	11.8	0	0
4	4	4	Colombia	Finca Santuario	CQU2023002	Finca Santuario	NaN	Coffee Quality Union	1850-2100	Popayan, Cauca	87.08	11.6	0	2
5	5	5	Guatemala	La Colina	The 2022 Pacific Rim Coffee Summit, GT02	Dinámica Café	NaN	Taiwan Coffee Laboratory	1668	Chimaltenango	87.00	10.7	0	0

- `print("--- 10 Baris Pertama Dataset ---")`: Menampilkan teks judul sebagai pemisah visual di output terminal/notebook.
 - `display(df.head(10))`: Menampilkan 10 baris pertama dataset dalam format tabel HTML yang rapi.
- Analisa Output:
- Kolom Redundan (Unnamed: 0): Terdapat kolom indeks bawaan dari penyimpanan CSV yang tidak memberikan informasi nilai apa pun.
 - Missing Value pada ICO Number: Nilai pada kolom ini terlihat dipenuhi NaN (Not a Number).
 - Inkonsistensi Format Altitude: Ketinggian kebun diinput dalam bentuk rentang teks (misal: "1700-1930") dan angka tunggal (misal: 1200), sehingga belum berformat numerik murni.
 - Data Kategori Teks Kompleks: Kolom Lot Number, Mill, dan Region memiliki variasi teks yang panjang dan berpotensi mengandung spasi atau karakter tidak standar.

Penjelasan Kode

B. Eksplorasi Data Awal

2. Informasi tipe data dan non-null count

```
print("\n--- Ringkasan Tipe Data & Struktur ---")
df.info()

--- Ringkasan Tipe Data & Struktur ---
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 207 entries, 0 to 206
Data columns (total 41 columns):
 #   Column              Non-Null Count  Dtype
---  -
 0   Unnamed: 0          207 non-null   int64
 1   ID                  207 non-null   int64
 2   Country of Origin   207 non-null   object
 3   Farm Name           205 non-null   object
 4   Lot Number          206 non-null   object
 5   Mill                204 non-null   object
 6   ICO Number          75 non-null    object
 7   Company             207 non-null   object
 8   Altitude            206 non-null   object
 9   Region              205 non-null   object
10  Producer            206 non-null   object
11  Number of Bags       207 non-null   int64
12  Bag Weight           207 non-null   object
13  In-Country Partner  207 non-null   object
14  Harvest Year         207 non-null   object
15  Grading Date         207 non-null   object
16  Owner                207 non-null   object
17  Variety              201 non-null   object
18  Status               207 non-null   object
19  Processing Method    202 non-null   object
20  Aroma                207 non-null   float64
21  Flavor               207 non-null   float64
22  Aftertaste           207 non-null   float64
23  Acidity              207 non-null   float64
24  Body                 207 non-null   float64
25  Balance              207 non-null   float64
26  Uniformity           207 non-null   float64
27  Clean Cup            207 non-null   float64
28  Sweetness            207 non-null   float64
29  Overall              207 non-null   float64
30  Defects              207 non-null   float64
31  Total Cup Points     207 non-null   float64
32  Moisture Percentage  207 non-null   float64
33  Category One Defects 207 non-null   int64
34  Quakers              207 non-null   int64
35  Color                207 non-null   object
36  Category Two Defects 207 non-null   int64
37  Expiration           207 non-null   object
38  Certification Body    207 non-null   object
39  Certification Address 207 non-null   object
40  Certification Contact 207 non-null   object
dtypes: float64(13), int64(6), object(22)
memory usage: 66.4+ KB
```

- `print("\n--- Ringkasan Tipe Data & Struktur ---")`: Menampilkan teks judul sebagai pemisah visual di terminal/notebook.
- ``df.info()``: Menampilkan ringkasan informasi struktur DataFrame, meliputi total baris, nama kolom, jumlah nilai terisi (non-null count), tipe data tiap kolom, dan penggunaan memori.

Analisa Output:

Dataset memiliki 207 baris (indeks 0–206) dan 41 kolom.

- 13 kolom float64: Skor penilaian cupping (seperti Aroma, Flavor, Aftertaste, Total Cup Points, dll.).
- 6 kolom int64: Variabel kuantitatif bulat/indeks (seperti Unnamed: 0, ID, Number of Bags, Defects, dll.).
- 22 kolom object: Variabel kualitatif/teks (seperti nama negara, kebun, tanggal, varietas, dll.).

Penjelasan Kode

B. Eksplorasi Data Awal

3. Memeriksa jumlah nilai kosong (missing values) per kolom

```
[7] print("\n--- Jumlah Missing Value per Kolom ---")
missing_values = df.isnull().sum()
print(missing_values[missing_values > 0])
```

--- Jumlah Missing Value per Kolom ---	
Farm Name	2
Lot Number	1
Mill	3
ICO Number	132
Altitude	1
Region	2
Producer	1
Variety	6
Processing Method	5

dtype: int64

Dataset yang digunakan memiliki beberapa missing value di beberapa kolom yang ada.

4. Memeriksa baris terduplikat

```
[8] print("\n--- Cek Baris Duplikat ---")
print(f"Jumlah baris duplikat: {df.duplicated().sum()}")
```

--- Cek Baris Duplikat ---	
Jumlah baris duplikat:	0

Dataset yang digunakan tidak memiliki data yang duplikat.

- `print("\n--- Jumlah Missing Value per Kolom ---")`: Menampilkan teks pemisah judul di output.
- `missing_values = df.isnull().sum()`: Memeriksa keberadaan nilai kosong (NaN) di setiap kolom dan menghitung totalnya.
- `print(missing_values[missing_values > 0])`: Menampilkan hanya kolom-kolom yang memiliki jumlah missing value lebih dari 0.
- `print("\n--- Cek Baris Duplikat ---")`: Menampilkan teks pemisah judul di output.
- `print(f"Jumlah baris duplikat: {df.duplicated().sum()}")`: Menghitung total baris yang identik/duplikat secara keseluruhan dan menampilkan hasilnya dalam format string.

Analisa Output:

- Terdapat beberapa kolom kategorikal dengan data kosong, seperti ICO Number (132), Variety (6), Processing Method (5), Mill (3), Farm Name (2), Region (2), Lot Number (1), Altitude (1), dan Producer (1).
- Dataset raw yang digunakan tidak terdapat data yang duplikat.

Penjelasan Kode

C. Menghapus Kolom Duplikat & Penanganan Missing Value

```
✓ C. Menghapus Kolom Duplikat (Redudansi) & Penanganan Missing Value
✓ 1. Menghapus kolom ID yang tidak digunakan

[9]
0d cols_to_drop = [
    col for col in ['Unnamed: 0', 'ICO Number'] if col in df.columns
]
df.drop(columns=cols_to_drop, inplace=True)
```

Menghapus kolom Unnamed karena fungsinya sama dengan kolom ID dan ICO Number dihapus karena data yang hilang dari kolom tersebut lebih dari setengah jumlah data.

- `cols_to_drop = [col for col in ['Unnamed: 0', 'ICO Number'] if col in df.columns]`: Membuat daftar kolom yang akan dihapus (Unnamed: 0 dan ICO Number) secara aman dengan mengecek ketersediaannya di DataFrame.
- `df.drop(columns=cols_to_drop, inplace=True)`: Menghapus kolom-kolom yang ada dalam daftar `cols_to_drop` secara langsung pada DataFrame asli (`inplace=True`).

Analisa Output:

- Kolom Unnamed: 0 berhasil dibuang untuk merapikan indeks, dan kolom ICO Number berhasil dihapus sehingga dataset terbebas dari kolom yang kehilangan >50% datanya.

Penjelasan Kode

D. Standarisasi Tipe Data Numerik

D. Standarisasi Tipe Data Numerik (Bag Weight & Altitude)

1. Ekstraksi angka berat bag dari teks '35 kg' -> 35.0

```
[286]
✓ 0 d
def convert_bag_weight(val):
    if pd.isna(val) or str(val).lower() == 'unknown':
        return np.nan
    val_str = str(val).lower().strip()

    numbers = re.findall(r'\d+(?:\.\d+)?', val_str)
    if not numbers:
        return np.nan

    weight = float(numbers[0])

    #Konversi ke KG
    if 'lbs' in val_str or 'pound' in val_str:
        weight = weight * 0.45359237
    elif 'g' in val_str and 'kg' not in val_str:
        weight = weight / 1000.0

    return weight

if 'Bag Weight' in df.columns:
    df['Bag Weight'] = df['Bag Weight'].apply(convert_bag_weight)

print('Standarisasi Bag Weight selesai!')
display(df[['Bag Weight']].head())
```

Standarisasi Bag Weight selesai!

	Bag Weight
0	35.0
1	80.0
2	25.0
3	22.0
4	24.0

Standarisasi data pada kolom Bag Weight yang memiliki teks seperti "35 kg" menjadi angka utamanya saja dengan menjadikannya nilai float 35.0.

- def convert_bag_weight(val): Membuat fungsi bernama convert_bag_weight untuk memproses setiap nilai dalam kolom Bag Weight.
- if pd.isna(val) or str(val).lower() == 'unknown': Mengecek apakah nilainya kosong (NaN) atau bernilai teks 'unknown'.
- return np.nan Jika nilainya kosong atau 'unknown', kembalikan sebagai nilai kosong (NaN).
- val_str = str(val).lower().strip() Mengubah nilai menjadi teks (string), diubah ke huruf kecil, dan dihapus spasi di awal/akhirnya.
- numbers = re.findall(r'\d+(?:\.\d+)?', val_str) Mencari dan mengambil karakter berbentuk angka (termasuk angka desimal) dari dalam teks.
- if not numbers: Mengecek apakah tidak ada angka sama sekali yang ditemukan di dalam teks.
- return np.nan Jika tidak menemukan angka, kembalikan nilai kosong (NaN).
- weight = float(numbers[0]) Mengambil angka pertama yang ditemukan lalu mengonversinya menjadi tipe data desimal (float).
- if 'lbs' in val_str or 'pound' in val_str: Mengecek apakah satuan dalam teks menggunakan lbs atau pound.
- weight = weight * 0.45359237 Mengonversi berat dari satuan pound/lbs menjadi kilogram (kg).
- elif 'g' in val_str and 'kg' not in val_str: Mengecek apakah satuannya gram (g) dan bukan kilogram (kg).
- weight = weight / 1000.0 Mengonversi berat dari satuan gram menjadi kilogram (kg).
- return weight Mengembalikan hasil nilai berat yang sudah bersih dan bersatuan kg.
- if 'Bag Weight' in df.columns: Memastikan bahwa kolom bernama 'Bag Weight' memang ada di dalam DataFrame (df).
- df['Bag Weight'] = df['Bag Weight'].apply(convert_bag_weight) Menerapkan fungsi convert_bag_weight ke seluruh baris pada kolom 'Bag Weight'.
- print('Standarisasi Bag Weight selesai!') Menampilkan pesan konfirmasi bahwa proses standarisasi sudah rampung.
- display(df[['Bag Weight']].head()) Menampilkan 5 baris teratas dari kolom 'Bag Weight' untuk melihat hasilnya.

Penjelasan Kode

D. Standarisasi Tipe Data Numerik

```
2. Konversi Altitude yang berupa range ('1700-1930') menjadi rerata numerik
```

```
[125]
✓ 0 d
def extract_altitude_mean(val):
    if pd.isna(val):
        return np.nan

    numbers = [float(s) for s in re.findall(r'\d+', str(val))]
    if len(numbers) >= 2:
        return sum(numbers[:2]) / 2
    elif len(numbers) == 1:
        return numbers[0]
    return np.nan

if 'Altitude' in df.columns:
    df['Altitude'] = df['Altitude'].apply(extract_altitude_mean)

print("Standarisasi Altitude selesai!")
display(df[['Altitude']].head())
```

Standarisasi Altitude selesai!

	Altitude
0	1815.0
1	1200.0
2	1300.0
3	1900.0
4	1975.0

Standarisasi data pada kolom Altitude yang memiliki data rentan seperti 1700-1930, kemudian mengambil data tengah-tengah atau mean, dari yang 1700-1930 nilai tengahnya 1815.

- `def extract_altitude_mean(val):` Membuat fungsi bernama `extract_altitude_mean` untuk mengekstrak dan menghitung rerata nilai ketinggian (altitude).
- `if pd.isna(val): return np.nan` Mengecek jika nilai pada sel kosong (NaN), maka biarkan tetap kosong (NaN).
- `numbers = [float(s) for s in re.findall(r'\d+', str(val))]` Menggunakan Regex untuk mencari semua kumpulan digit angka dari dalam teks, lalu mengonversi setiap angka tersebut menjadi tipe float.
- `if len(numbers) >= 2:` Mengecek jika angka yang ditemukan ada 2 atau lebih (menandakan format rentang/range seperti '1700-1930').
- `return sum(numbers[:2]) / 2` Mengambil dua angka pertama dari rentang tersebut, menjumlahkannya, lalu membaginya dengan 2 untuk mendapatkan nilai rata-ratanya.
- `elif len(numbers) == 1:` Mengecek jika hanya ada 1 angka yang ditemukan dalam teks (bukan bentuk rentang).
- `return numbers[0]` Mengembalikan nilai tunggal angka tersebut secara langsung.
- `return np.nan` Mengembalikan nilai kosong (NaN) jika tidak ada pola angka sama sekali yang berhasil diekstrak.
- `if 'Altitude' in df.columns:` Memastikan bahwa kolom 'Altitude' benar-benar ada di dalam DataFrame `df`.
- `df['Altitude'] = df['Altitude'].apply(extract_altitude_mean)` Menerapkan fungsi `extract_altitude_mean` ke seluruh baris dan langsung menimpa (overwrite) nilai pada kolom 'Altitude'.
- `print("Standarisasi Altitude selesai!")` Menampilkan pesan konfirmasi bahwa proses standarisasi kolom ketinggian telah selesai.
- `display(df[['Altitude']].head())` Menampilkan 5 baris pertama dari kolom 'Altitude' yang nilainya sudah dikonversi menjadi numerik desimal (float).

Penjelasan Kode

E. Standarisasi Datetime

```
✓ E. Standarisasi Tipe Data Tanggal (Grading Date & Expiration)

✓ 1. Membuat Fungsi untuk Standarisasi, Pembersihan, dan Konversi ke pd.to_datetime

[288]
✓ 0 d
date_cols = ['Grading Date', 'Expiration']

for col in date_cols:
    if col in df.columns:
        df[col] = pd.to_datetime(df[col], errors='coerce', format='mixed')

print('Format tanggal berhasil diubah ke datetime64!')
display(df[date_cols].dtypes)
display(df[date_cols].head())

Format tanggal berhasil diubah ke datetime64!
0
Grading Date  datetime64[ns]
Expiration    datetime64[ns]

dtype: object
Grading Date  Expiration
0    2022-09-21  2023-09-21
1    2022-11-15  2023-11-15
2    2022-11-15  2023-11-15
3    2022-09-21  2023-09-21
4    2023-03-06  2024-03-05
```

Standarisasi kolom Grading Date dan Expiration yang datanya merupakan tanggal dari st, nd, rd, th. Dijadikan tanggal dengan format YYYY-MM-DD

- `date_cols = ['Grading Date', 'Expiration']` Membuat daftar (list) berisi nama kolom tanggal yang akan diproses, yaitu 'Grading Date' dan 'Expiration'.
- `for col in date_cols:` Melakukan perulangan (looping) untuk memproses setiap kolom yang ada di dalam daftar `date_cols` satu per satu.
- `if col in df.columns:` Mengecek apakah kolom tersebut benar-benar ada di dalam DataFrame (`df`).
- `df[col] = pd.to_datetime(df[col], errors='coerce', format='mixed')` Mengonversi isi kolom menjadi tipe data tanggal (`datetime64`). Parameter `errors='coerce'` mengubah nilai yang rusak/invalid menjadi `NaT` (kosong), dan `format='mixed'` menangani beragam format tanggal yang berbeda.
- `print('Format tanggal berhasil diubah ke datetime64!')` Menampilkan pesan konfirmasi bahwa proses konversi tipe data tanggal telah berhasil.
- `display(df[date_cols].dtypes)` Menampilkan tipe data dari kolom Grading Date dan Expiration untuk memastikan tipe datanya sudah berubah menjadi `datetime64[ns]`.
- `display(df[date_cols].head())` Menampilkan 5 baris pertama dari kolom tanggal untuk melihat hasil perubahan formatnya.

Penjelasan Kode

F. Pembersihan Aksara Non-Latin

F. Pembersihan Aksara Non-Latin

Standarisasi kolom yang datanya memiliki aksara non-Latin, dengan menyisakan datanya berupa alfabet Latin

1. Membuat Fungsi untuk Menghapus Aksara Non-Latin dan Mempertahankan Karakter Latin

```
def remove_non_latin(text):
    if pd.isna(text) or not isinstance(text, str):
        return text

    # Menghapus aksara non-Latin
    cleaned_text = re.sub(r'^\x00-\x7F|+', '', text)
    cleaned_text = ' '.join(cleaned_text.split())

    # Jika string jadi kosong setelah dihapus, ganti ke Unknown
    return cleaned_text if cleaned_text else 'Unknown'

# Menerapkan pada semua kolom teks (object)
text_cols = df.select_dtypes(include=['object']).columns
for col in text_cols:
    df[col] = df[col].apply(remove_non_latin)

print('Pembersihan karakter non-Latin selesai!')

display(df[text_cols].head())
```

Pembersihan karakter non-Latin selesai!

	Country of Origin	Farm Name	Lot Number	Mill	Company	Region	Producer	In-Country Partner	Harvest Year	Owner
0	Colombia	Finca El Paraiso	CQU2022015	Finca El Paraiso	Coffee Quality Union	Piendam, Cauca	Diego Samuel Bermudez	Japan Coffee Exchange	2021 / 2022	Coffee Quality Union
1	Taiwan	Royal Bean Geisha Estate	The 2022 Pacific Rim Coffee Summit, T037	Royal Bean Geisha Estate	Taiwan Coffee Laboratory	Chiayi	Unknown	Taiwan Coffee Laboratory	2021 / 2022	Taiwan Coffee Laboratory
2	Laos	OKLAO coffee farms	The 2022 Pacific Rim Coffee Summit, LA01	oklao coffee processing plant	Taiwan Coffee Laboratory	Laos Borofen Plateau	WU TAO CHI	Taiwan Coffee Laboratory	2021 / 2022	Taiwan Coffee Laboratory
3	Costa Rica	La Cumbre	CQU2022017	La Montana Tarrazu Mill	Coffee Quality Union	Los Santos, Tarrazu	Santa Maria de Dota	Japan Coffee Exchange	2022	Coffee Quality Union
4	Colombia	Finca Santuario	CQU2023002	Finca Santuario	Coffee Quality Union	Popayan, Cauca	Camilo Merizalde	Japan Coffee Exchange	2022	Coffee Quality Union

- def remove_non_latin(text): Membuat fungsi bernama remove_non_latin untuk mendeteksi dan menghapus karakter non-Latin.
- if pd.isna(text) or not isinstance(text, str): Mengecek apakah nilai bersifat kosong (NaN) atau bukan berupa teks (string).
- return text Jika nilainya kosong atau bukan teks, langsung kembalikan nilai aslinya tanpa diproses.
- cleaned_text = re.sub(r'^\x00-\x7F|+', '', text) Menghapus semua karakter di luar rentang ASCII (seperti aksara Kanji, Mandarin, Thai, emoji, dll.) dan menyisakan huruf/angka Latin.
- cleaned_text = ' '.join(cleaned_text.split()) Merapikan dan menghapus spasi ganda atau berlebih yang tersisa dari hasil pembersihan.
- return cleaned_text if cleaned_text else 'Unknown' Mengembalikan teks yang sudah bersih; jika teks menjadi kosong setelah karakter non-Latin dihapus, ubah nilainya menjadi 'Unknown'.
- text_cols = df.select_dtypes(include=['object']).columns Mengambil dan mengumpulkan semua nama kolom di DataFrame yang bertipe data teks (object).
- for col in text_cols: Melakukan perulangan (looping) untuk memproses setiap kolom teks satu per satu.
- df[col] = df[col].apply(remove_non_latin) Menerapkan fungsi remove_non_latin ke seluruh baris dalam kolom teks tersebut.
- print('Pembersihan karakter non-Latin selesai!') Menampilkan pesan konfirmasi bahwa pembersihan karakter non-Latin sudah selesai.
- display(df[text_cols].head()) Menampilkan 5 baris pertama dari seluruh kolom teks untuk memperlihatkan hasilnya.

Penjelasan Kode

G. Pembersihan Spasi & Deduplikasi Data Kembali

✓ G. Pembersihan Spasi & Deduplikasi Data

✓ 1. Membersihkan spasi berlebih di awal dan akhir teks pada semua kolom string

```
[18] ✓ 0 d object_cols = df.select_dtypes(include=['object']).columns
for col in object_cols:
    df[col] = df[col].astype(str).str.strip()
```

✓ 2. Cek dan hapus data duplikat jika ada

```
[19] ✓ 0 d initial_count = len(df)
df.drop_duplicates(inplace=True)
final_count = len(df)

print(
    f" Bersihkan spasi selesai! Baris duplikat yang dihapus: {initial_count - final_count}"
)
```

✓ Bersihkan spasi selesai! Baris duplikat yang dihapus: 0

- `object_cols = df.select_dtypes(include=['object']).columns`: Mengambil seluruh nama kolom yang memiliki tipe data object (string/teks) dari DataFrame.
- `for col in object_cols::` Melakukan perulangan untuk memproses setiap kolom bertipe object satu per satu.
- `df[col] = df[col].astype(str).str.strip()`: Memastikan kolom konversi ke string lalu membuang spasi liar di awal dan akhir teks menggunakan fungsi `.str.strip()`.
- `initial_count = len(df)`: Menyimpan jumlah total baris dataset sebelum eliminasi duplikat ke dalam variabel `initial_count`.
- `df.drop_duplicates(inplace=True)`: Menghapus baris yang identik/duplikat secara permanen pada DataFrame asli.
- `final_count = len(df)`: Menyimpan jumlah total baris dataset setelah proses eliminasi duplikat ke dalam variabel `final_count`.
- `print(f"Bersihkan spasi selesai! Baris duplikat yang dihapus: {initial_count - final_count}")`: Menghitung selisih jumlah baris awal dan akhir, lalu menampilkan total baris duplikat yang berhasil dihapus.

Penjelasan Kode

H. Ringkasan Akhir & Export DS

H. Ringkasan Akhir & Export Dataset Clean

1. Ringkasan info dataset yang sudah bersih

```
[184] print("--- Info Dataset Hasil Cleansing ---")
[185] df.info()
[186] display(df.head())
```

Info Dataset Hasil Cleansing ---

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 207 entries, 0 to 206

Data columns (total 39 columns):

Column Non-Null Count Dtype

0 ID 207 non-null int64

1 Country of Origin 207 non-null object

2 Farm Name 207 non-null object

3 Lot Number 207 non-null object

4 Mill 207 non-null object

5 Company 207 non-null object

6 Altitude 206 non-null float64

7 Region 207 non-null object

8 Producer 207 non-null object

9 Number of Bags 207 non-null int64

10 Bag Weight 207 non-null float64

11 In-Country Partner 207 non-null object

12 Harvest Year 207 non-null object

13 Grading Date 207 non-null object

14 Owner 207 non-null object

15 Variety 207 non-null object

16 Status 207 non-null object

17 Processing Method 207 non-null object

18 Aroma 207 non-null float64

19 Flavor 207 non-null float64

20 Aftertaste 207 non-null float64

21 Acidity 207 non-null float64

22 Body 207 non-null float64

23 Balance 207 non-null float64

24 Uniformity 207 non-null float64

25 Clean cup 207 non-null float64

26 Sweetness 207 non-null float64

27 Overall 207 non-null float64

28 Defects 207 non-null float64

29 Total Cup Points 207 non-null float64

30 Moisture Percentage 207 non-null float64

31 Category One Defects 207 non-null int64

32 Quakers 207 non-null int64

33 Color 207 non-null object

34 Category Two Defects 207 non-null int64

35 Expiration 207 non-null object

36 Certification Body 207 non-null object

37 Certification Address 207 non-null object

38 Certification Contact 207 non-null object

Altitude	Region	Producer	Number of Bags
1815.0	Piendamo,Cauca	Diego Samuel Bermudez	1
1200.0	Chiayi	Unknown	1
1300.0	Laos Borofen Plateau	WU TAO CHI	19
1900.0	Los Santos,Tarrazu	Santa Maria de Dota	1
1975.0	Popayan,Cauca	Camilo Merizalde	2

- print("--- Info Dataset Hasil Cleansing ---") Menampilkan teks judul sebagai penanda header pada tampilan output.
 - df.info() Menampilkan ringkasan struktur DataFrame, termasuk total baris, nama kolom, jumlah nilai non-null, dan tipe data setiap kolom.
 - display(df.head()) Menampilkan 5 baris pertama dari DataFrame untuk melihat pratinjau data secara visual.
- Anallisa Output:
- Dataset terdiri dari 207 baris (indeks 0–206) dan 39 kolom.
 - Sebagian besar kolom memiliki 207 non-null (lengkap tanpa nilai kosong), kecuali kolom Altitude yang tercatat 206 non-null.
 - Tipe data terdiri dari 2 kolom datetime64 (Grading Date & Expiration), 15 kolom float64, 5 kolom int64, dan 17 kolom object/kategorikal.
 - Menampilkan 5 baris teratas dataset dengan nilai yang sudah bersih dan rapi (misalnya Altitude berupa angka float 1815.0, Expiration berformat tanggal 2023-09-21, serta teks non-Latin yang telah disaring).

Penjelasan Kode

H. Ringkasan Akhir & Export DS

2. Simpan dataset hasil pembersihan ke Google Drive

```
[311]
✓ Od
output_file = (
    '/content/drive/MyDrive/2026GoogleColab_DataMining/Tugas1/2318039_df_arabica_cleaned.csv'
)
df.to_csv(output_file, index=False)

print(f"\n Dataset bersih berhasil disimpan ke: {output_file}")

Dataset bersih berhasil disimpan ke: /content/drive/MyDrive/2026GoogleColab_DataMining/Tugas1/2318039_df_arabica_cleaned.csv
```

- `output_file = (...)` Menyimpan jalur direktori (path) dan nama file CSV tujuan simpan ke dalam variabel `output_file`.
- `'/content/drive/MyDrive/2026GoogleColab_DataMining/Tugas1/2318039_df_arabica_cleaned.csv'` Lokasi spesifik di Google Drive tempat dataset hasil pembersihan akan disimpan.
- `df.to_csv(output_file, index=False)` Mengekspor/menyimpan DataFrame (`df`) yang sudah bersih menjadi file CSV. Parameter `index=False` digunakan agar nomor indeks baris tidak ikut tersimpan sebagai kolom baru.
- `print(f"\n Dataset bersih berhasil disimpan ke: {output_file}")` Menampilkan pesan konfirmasi di layar beserta lokasi file CSV yang berhasil disimpan.

Hasil Akhir

Berikut hasil akhir dataset `df_arabica.csv` yang telah melalui seluruh tahapan preprocessing. Kolom `unnamed` dan `ICO Number` yang redundan telah dihapus, seluruh missing value pada data teks diisi dengan label `Unknown`, dan nilai numerik pada `Bag Weight` serta `Altitude` berhasil diekstraksi dan dikonversi ke satuan standar (kg dan meter). Selain itu, kolom tanggal `Grading Date` dan `Expiration` diseragamkan ke format `YYYY-MM-DD` bertipe `datetime64`, serta seluruh aksara non-Latin pada kolom kategorikal telah dibersihkan sehingga dataset kini benar-benar rapi, konsisten, dan siap digunakan untuk analisis lebih lanjut.

	ID		Country of Origin	Farm Name	Lot Number	Mill	Company	Altitude	Region	Producer	Number of Bags	Bag Weight	In-Country Partner	Harvest Year	Grading Date	Owner	Variety
2	0	Colombia	Finca El Paraiso	CQU2022015	Finca El Paraiso	Coffee Quality Union		1815	Piendamocauca	Diego Samuel Bernal	1	35	Japan Coffee Exchange	2021 / 2022	2022-09-21	Coffee Quality Union	Castillo
3	1	Taiwan	Royal Bean Geisha	The 2022 Pacific Rim	Royal Bean Geisha	Taiwan Coffee Labo		1200	Chiayi	Unknown	1	80	Taiwan Coffee Labo	2021 / 2022	2022-11-15	Taiwan Coffee Labo	Geshawana
4	2	Laos	OKLAO coffee farms	The 2022 Pacific Rim	oklao coffee process	Taiwan Coffee Labo		1300	Laos Borofen Plateau	WU TAO CHI	19	25	Taiwan Coffee Labo	2021 / 2022	2022-11-15	Taiwan Coffee Labo	Java
5	3	Costa Rica	La Cumbre	CQU2022017	La Montana Tarrazu	Coffee Quality Union		1900	Los Santos,Tarrazu	Santa Maria de Dota	1	22	Japan Coffee Exchange	2022	2022-09-21	Coffee Quality Union	Geshawana
6	4	Colombia	Finca Santuario	CQU2023002	Finca Santuario	Coffee Quality Union		1975	Popayan,Cauca	Camilo Merizalde	2	24	Japan Coffee Exchange	2022	2023-03-06	Coffee Quality Union	Red Bourbon
7	5	Guatemala	La Colina	The 2022 Pacific Rim	Dinmica Caf	Taiwan Coffee Labo		1668	Chimaltenango	Emilio Antonio Medina	5	30	Taiwan Coffee Labo	2022	2022-11-15	Taiwan Coffee Labo	Geshawana
8	6	Taiwan	Melastoma Coffee Estate	The 2022 Pacific Rim	Unknown	Taiwan Coffee Labo		1250	Chiayi	Unknown	1	27	Taiwan Coffee Labo	2021 / 2022	2022-11-15	Taiwan Coffee Labo	Geshawana
9	7	Taiwan	Chi Tsai Liu Li Ecology	The 2022 Pacific Rim	Unknown	Taiwan Coffee Labo		1200	Chiayi	Unknown	1	90	Taiwan Coffee Labo	2021 / 2022	2022-11-15	Taiwan Coffee Labo	SL34+
10	8	Taiwan	Liang Xuan Coffee Farm	The 2022 Pacific Rim	Unknown	Taiwan Coffee Labo		1250	Chiayi	Unknown	1	30	Taiwan Coffee Labo	2021 / 2022	2022-11-15	Taiwan Coffee Labo	SL34
11	9	Tanzania, United Republic of	MASHIMA AMCOS	CN 4127230034/418	GOURMET COFFEE	DORMAN (T) LIMITED		1550	KILIMANJARO	DORMAN (T) LIMITED	320	60	Kenya Coffee Trader	2022 / 2023	2023-02-01	Gilbert Maina	Bourbon
12	10	Ethiopia	TADE GG	010/0296/600	Moledo	Marubeni corp.,		2000	Guji	Tesfaye Bekele Degu	10	30	Japan Coffee Exchange	2021 / 2022	2022-05-31	ERI ASAEADA	Ethiopian
13	11	Guatemala	Karen Acajabon Coffee	The 2022 Pacific Rim	Cafetoland	Taiwan Coffee Labo		2000	Acatenango	Karen Acajabon	5	15	Taiwan Coffee Labo	2021	2022-11-15	Full Sweet Coffee	Geshawana
14	12	Taiwan	Goodfun Coffee Farm	The 2022 Pacific Rim	Unknown	Taiwan Coffee Labo		1250	Yunlin	Unknown	1	60	Taiwan Coffee Labo	2021 / 2022	2022-11-15	Goodfun	Geshawana
15	13	Ethiopia	Gelana Geisha	Grade 1, Guji, Natural	Dry Mill or Hulling Facility	Kerchanshe Trading		1950	Guji	Kerchanshe	40	60	METAD Agricultural	2021 / 2022	2022-08-26	Isreal Degefa	Geshawana
16	14	Colombia	La Gaitania	The 2022 Pacific Rim	La Gaitania	Taiwan Coffee Labo		1850	tolima	Josue Enciso Suarez	70	35	Taiwan Coffee Labo	2021 / 2022	2022-11-15	PeiHsun Lin	Caturra
17	15	Taiwan	Unknown	The 2022 Pacific Rim	Unknown	Taiwan Coffee Labo		1100	Chiayi	Unknown	1	60	Taiwan Coffee Labo	2021 / 2022	2022-11-15	Taiwan Coffee Labo	SL34
18	16	Ethiopia	Halo Bariti Cooperative	CQU2023006	Halo Bariti Cooperative	Coffee Quality Union		2000	Gedeb,Yirgacheffe,Shashane	Halo Bariti Cooperative	8	5	Japan Coffee Exchange	2022	2023-04-07	Coffee Quality Union	Woliso
19	17	Taiwan	Unknown	202203	yes	Dongbi coffee		1300	Shibi, Gukeng Township	Unknown	5	2	Blossom Valley Inter	2022	2022-10-24	Dongbi	Geshawana
20	18	Taiwan	Unknown	202112	yes	Unknown		1200	Gukeng Township, Yunlin	Unknown	8	1	Blossom Valley Inter	2021 / 2022	2022-10-24	Unknown	Geshawana
21	19	Tanzania, United Republic of	BURKA	CN 4127230032/P-9	GOURMET COFFEE	DORMAN (T) LIMITED		1585	Arusha	DORMAN (T) LIMITED	200	30	Kenya Coffee Trader	2022 / 2023	2023-02-01	Gilbert Maina	Bourbon
22	20	Guatemala	Finca Vista Hermosa	The 2022 Pacific Rim	El Vergel	Taiwan Coffee Labo		1900	Guatemala, Fraijanes	Fredy Orantes	8	30	Taiwan Coffee Labo	2021 / 2022	2022-11-15	Carlos Pascual -	Geshawana
23	21	Taiwan	Uncle Chung's Coffee	2022/03	Uncle Chung's Coffee	Taiwan Coffee Labo		850	Zhuoxi Township	YU TING YU	1	20	Taiwan Coffee Labo	2022	2022-12-12	Yu Ting Yu	Typical
24	22	Thailand	Hom Doi	1	Machines to peel out	Lyrose		1600	Chiang Mai	Liau farmers	2	1	FABB Academy of Coffee	2021 / 2022	2022-08-16	Christian Chamette	Catimor
25	23	Colombia	El Diamante	CQU2023005	El Diamante	Coffee Quality Union		1350	Quindio	Farm Bedoya Arango	6	5	Japan Coffee Exchange	2022	2023-04-07	Coffee Quality Union	Castillo
26	24	Taiwan	Unknown	The 2022 Pacific Rim	Unknown	Taiwan Coffee Labo		1250	Yunlin	Unknown	4	50	Taiwan Coffee Labo	2021 / 2022	2022-11-15	Taiwan Coffee Labo	SL34
27	25	Brazil	Fazenda Recreio	Arara 1	Dry mill	WIT wealth, investment		1250	Regio Vulcnica	Diogo T. Dias de M	25	60	Brazil Specialty Coffee	2022	2023-01-06	Andre Clark	nan
28	26	Taiwan	ZouZhouYuan	The 2022 Pacific Rim	ZouZhouYuan	Taiwan Coffee Labo		1300	Chiayi	Unknown	1	100	Taiwan Coffee Labo	2021 / 2022	2022-11-15	Fang, Cheng Lun	Geshawana
29	27	Taiwan	Unknown	The 2022 Pacific Rim	Unknown	Taiwan Coffee Labo		1200	Yunlin	Unknown	1	90	Taiwan Coffee Labo	2021 / 2022	2022-11-15	Jihh Hao,GUO	Geshawana
30	28	Taiwan	Unknown	The 2022 Pacific Rim	Unknown	Taiwan Coffee Labo		1060	Chiayi	Unknown	1	85	Taiwan Coffee Labo	2021 / 2022	2022-11-15	Taiwan Coffee Labo	Geshawana
31	29	United States (Hawaii)	Hokukano Ranch	The 2022 Pacific Rim	Kona Coffee & Tea	Taiwan Coffee Labo		600	Kona	Kona Hills LLC	80	15	Taiwan Coffee Labo	2021 / 2022	2022-11-15	Taiwan Coffee Labo	Typical
32	30	Taiwan	Siang-Ting Organic	2022/3(1)	Siang-Ting Organic	Taiwan Coffee Labo		200	Shoufeng Township	Zhang Jin-Yi	3	48	Taiwan Coffee Labo	2022	2022-12-12	Zhang Jin Yi	Typical

Kesimpulan

Proses preprocessing pada dataset Arabica Coffee telah berhasil dilakukan untuk mengubah data mentah menjadi dataset yang bersih, terstruktur, dan siap dianalisis.



Berikut adalah poin-poin utama dari tahapan yang telah dikerjakan:

- **Eliminasi Redundansi:** Menghapus kolom yang tidak relevan seperti Unnamed: 0 dan ICO Number untuk merapikan struktur data.
- **Standarisasi Numerik:** Ekstraksi angka pada Bag Weight dengan konversi satuan (lbs/gram ke kg) serta perhitungan nilai rata-rata pada Altitude.
- **Konsistensi Tipe Tanggal:** Mengubah kolom Grading Date dan Expiration menjadi format standar YYYY-MM-DD bertipe datetime64.
- **Pembersihan Aksara Non-Latin:** Menghapus karakter di luar alfabet Latin (seperti Kanji/Mandarin) pada kolom teks agar entitas data lebih seragam.
- **Penanganan Missing Values:** Mengisi semua entitas teks yang kosong atau hilang dengan label 'Unknown' sehingga dataset akhir bebas dari missing values.

Dokumentasi

Jum'at, 25 September 2026

Dokumentasi Tugas Kelas



Dokumentasi Mengikuti Kelas



*Saya yang ditandai dengan huruf 'x' warna putih



Thank You

for your time and attention

✉ eoliasuwandi@gmail.com

🐙 Github: <https://github.com/seal165>

in LinkedIn: <https://www.linkedin.com/in/eolia-shalbillah-gadis>